

Name :- Shounak Lohokare

Roll num :- 21611

▼ K - nearest neighbour algorithm

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
```

```
from google.colab import drive
drive.mount('/content/drive')
```

Mounted at /content/drive

```
df=pd.read_csv('/content/drive/MyDrive/Colab Notebooks/Data Mining Data/Social_Network_Ads
df
```

	User ID	Gender	Age	EstimatedSalary	Purchased
0	15624510	Male	19	19000	0
1	15810944	Male	35	20000	0
2	15668575	Female	26	43000	0
3	15603246	Female	27	57000	0
4	15804002	Male	19	76000	0
...
395	15691863	Female	46	41000	1
396	15706071	Male	51	23000	1
397	15654296	Female	50	20000	1
398	15755018	Male	36	33000	0
399	15594041	Female	49	36000	1

400 rows × 5 columns

```
a = pd.DataFrame(df,columns = ['Age','EstimatedSalary'])
a
```

	Age	EstimatedSalary
0	19	19000
1	35	20000
2	26	43000
3	27	57000
4	19	76000
...
395	46	41000
396	51	23000
397	50	20000
398	36	33000
399	49	36000

```
x = a.to_numpy()
y = df.Purchased
print(x)
print(y)
```

```
[[ 19 19000]
 [ 35 20000]
 [ 26 43000]
 [ 27 57000]
 [ 19 76000]
 [ 27 58000]
 [ 27 84000]
 [ 32 150000]
 [ 25 33000]
 [ 35 65000]
 [ 26 80000]
 [ 26 52000]
 [ 20 86000]
 [ 32 18000]
 [ 18 82000]
 [ 29 80000]
 [ 47 25000]
 [ 45 26000]
 [ 46 28000]
 [ 48 29000]
 [ 45 22000]
 [ 47 49000]
 [ 48 41000]
 [ 45 22000]
 [ 46 23000]
 [ 47 20000]
 [ 49 28000]
 [ 47 30000]
 [ 29 43000]
 [ 31 18000]
 [ 31 74000]
 [ 27 137000]
```

```
[ 21 16000]
[ 28 44000]
[ 27 90000]
[ 35 27000]
[ 33 28000]
[ 30 49000]
[ 26 72000]
[ 27 31000]
[ 27 17000]
[ 33 51000]
[ 35 108000]
[ 30 15000]
[ 28 84000]
[ 23 20000]
[ 25 79000]
[ 27 54000]
[ 30 135000]
[ 31 89000]
[ 24 32000]
[ 18 44000]
[ 29 83000]
[ 35 23000]
[ 27 58000]
[ 24 55000]
[ 23 48000]
[ 28 79000]
```

```
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.15)
print(x_train)
```

```
[[ 38 50000]
[ 52 114000]
[ 20 74000]
[ 37 53000]
[ 45 131000]
[ 47 49000]
[ 39 73000]
[ 27 57000]
[ 41 30000]
[ 26 81000]
[ 52 21000]
[ 36 75000]
[ 47 113000]
[ 26 35000]
[ 35 55000]
[ 41 63000]
[ 35 20000]
[ 51 146000]
[ 30 62000]
[ 35 147000]
[ 26 32000]
[ 26 86000]
[ 35 57000]
[ 42 104000]
[ 60 42000]
[ 39 75000]
[ 35 58000]
[ 28 89000]
[ 37 33000]
```

```
[ 35 72000]
[ 45 26000]
[ 27 96000]
[ 42 70000]
[ 30 107000]
[ 33 43000]
[ 25 87000]
[ 37 77000]
[ 60 108000]
[ 46 74000]
[ 39 96000]
[ 40 72000]
[ 20 82000]
[ 37 78000]
[ 29 61000]
[ 48 131000]
[ 37 79000]
[ 45 22000]
[ 24 23000]
[ 33 69000]
[ 26 15000]
[ 41 72000]
[ 19 21000]
[ 54 108000]
[ 37 71000]
[ 50 88000]
[ 28 59000]
[ 19 85000]
[ 46 23000]
```

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
scaler.fit(x_train)
x_train = scaler.transform(x_train)
x_test = scaler.transform(x_test)
print(x_train)
```

```
[[ 0.03902949 -0.60714766]
 [ 1.38526409  1.25862457]
 [-1.69184357  0.09251692]
 [-0.05713012 -0.51968959]
 [ 0.71214679  1.75422032]
 [ 0.90446602 -0.63630035]
 [ 0.1351891   0.06336423]
 [-1.01872627 -0.40307883]
 [ 0.32750833 -1.19020149]
 [-1.11488588  0.29658576]
 [ 1.38526409 -1.45257571]
 [-0.15328974  0.12166961]
 [ 0.90446602  1.22947188]
 [-1.11488588 -1.04443803]
 [-0.24944935 -0.46138421]
 [ 0.32750833 -0.22816268]
 [-0.24944935 -1.4817284 ]
 [ 1.28910448  2.19151068]
 [-0.73024742 -0.25731537]
 [-0.24944935  2.22066337]
 [-1.11488588 -1.1318961 ]
 [-1.11488588  0.44234922]
```

```

[-0.24944935 -0.40307883]
[ 0.42366795  0.96709766]
[ 2.15454101 -0.84036919]
[ 0.1351891   0.12166961]
[-0.24944935 -0.37392613]
[-0.92256665  0.52980729]
[-0.05713012 -1.10274341]
[-0.24944935  0.03421154]
[ 0.71214679 -1.30681225]
[-1.01872627  0.73387613]
[ 0.42366795 -0.02409384]
[-0.73024742  1.05455573]
[-0.44176858 -0.8112165 ]
[-1.2110455   0.47150191]
[-0.05713012  0.179975 ]
[ 2.15454101  1.08370842]
[ 0.80830641  0.09251692]
[ 0.1351891   0.73387613]
[ 0.23134872  0.03421154]
[-1.69184357  0.32573845]
[-0.05713012  0.20912769]
[-0.82640704 -0.28646806]
[ 1.00062563  1.75422032]
[-0.05713012  0.23828038]
[ 0.71214679 -1.42342301]
[-1.30720511 -1.39427032]
[-0.44176858 -0.05324653]
[-1.11488588 -1.62749185]
[ 0.32750833  0.03421154]
[-1.78800318 -1.45257571]
[ 1.57758332  1.08370842]
[-0.05713012  0.00505885]
[ 1.19294486  0.5006546 ]
[-0.92256665 -0.34477344]
[-1.78800318  0.41319652]
[ 0.80830641 -1.39427032]

```

```

from sklearn.neighbors import KNeighborsClassifier
classifier = KNeighborsClassifier(n_neighbors=10,metric='manhattan')
classifier.fit(x_train, y_train)

```

```
KNeighborsClassifier(metric='manhattan', n_neighbors=10)
```

```

y_pred = classifier.predict(x_test)
print(y_pred," ",y_test)

```

```

[0 0 1 0 0 0 0 1 0 1 1 0 0 0 0 1 0 0 1 1 0 0 1 0 0 1 0 1 1 1 0 0 0 0 1 0 0
 0 0 1 0 0 1 1 0 1 1 0 0 1 0 1 0 0 0 0 0 0 0 0]      374      0
116      0
316      1
8        0
72       0
187      0
175      0
369      1
256      0
396      1
264      1

```

```
78      0
33      0
237     0
39      0
274     1
343     1
276     0
233     1
22      1
68      0
125     0
393     1
398     0
193     0
31      1
58      0
290     1
7       1
391     1
44      0
110     0
118     0
301     1
361     1
251     0
177     0
11      0
151     0
375     1
267     0
76      0
26      1
219     1
330     0
329     1
291     1
353     0
83      0
371     1
244     0
91      0
325     0
124     0
134     0
49      0
222     0
```

```
from sklearn.metrics import classification_report, confusion_matrix
print(confusion_matrix(y_test, y_pred))
print(classification_report(y_test, y_pred))
```

```
[[38  1]
 [ 2 19]]
```

	precision	recall	f1-score	support
0	0.95	0.97	0.96	39
1	0.95	0.90	0.93	21
accuracy			0.95	60
macro avg	0.95	0.94	0.94	60

weighted avg	0.95	0.95	0.95	60
--------------	------	------	------	----

```
error = []
```

```
# Calculating error for K values between 1 and 40
```

```
for i in range(1, 40):
```

```
    knn = KNeighborsClassifier(n_neighbors=i)
```

```
    knn.fit(x_train, y_train)
```

```
    pred_i = knn.predict(x_test)
```

```
    error.append(np.mean(pred_i != y_test))
```

```
print(error)
```

```
[0.1]
```

```
[0.1, 0.1333333333333333]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
[0.1, 0.1333333333333333, 0.0833333333333333, 0.0666666666666667, 0.0666666666666667]
```

```
plt.figure(figsize=(12, 6))
```

```
plt.plot(range(1, 40), error, color='red', linestyle='dashed', marker='o',
```

```
markerfacecolor='blue', markersize=10)  
plt.title('Error Rate K Value')  
plt.xlabel('K Value')  
plt.ylabel('Mean Error')
```

```
Text(0, 0.5, 'Mean Error')
```

